Relatório da Palestra

Tecnologias Aplicadas à Saúde
ERClinic

Professor: Alexandre Zamberlan
Apresentador: Robertson Ebling – Co-fundador da ER Clinic
Aluno: Bruno Difante de Moraes da Silva
Disciplina: Tecnologias Inteligentes Aplicadas à Saúde

---

1. Técnicas de IA utilizadas e em quais situações/cenários

O quadro abaixo resume as técnicas apresentadas e o cenário em que cada uma é aplicada na ER Clinic. Em seguida, cada uma é detalhada.

Técnica de IA	**Situação/cenário**
Aprendizado de Máquina supervisionado (XGBoost)	Alerta de risco de não comparecimento (falta) a consultas agendadas
Chatbot com LLM e agentes, usando *endpoints* de API	Agendamento automático via WhatsApp, 24 horas por dia
Reconhecimento de fala (*speech-to-text*) + LLM + engenharia de *prompt*	Transcrição da consulta e preenchimento automático do prontuário
LLM multimodal + engenharia de *prompt*	Análise de exames enviados em foto ou PDF
LLM de sumarização + engenharia de *prompt*	Resumo automático do prontuário, com links para a origem
RAG (*Retrieval-Augmented Generation*)	Copiloto Clínico Córtex, com consulta a protocolos e documentos do médico
Visão computacional (planejada)	Cervix: assistente de laudos para colposcopia

1.1 Aprendizado de Máquina supervisionado: alerta de risco de falta

Utiliza-se **XGBoost**, algoritmo baseado em árvores de decisão combinadas (*gradient boosting*), para um problema de **classificação binária com estimativa probabilística**: dado um agendamento, o modelo estima a probabilidade de o paciente faltar. O treino é supervisionado, pois cada agendamento histórico está associado a um resultado conhecido (compareceu ou não compareceu), usando dados reais, históricos e estruturados da própria plataforma.

- **Variáveis (*features*):** nove no total, entre elas histórico de faltas, taxa de faltas anteriores, resultado da última consulta, convênio, teleconsulta, agendamento online, dia da semana e horário da consulta.

- **Inferência:** ao criar um agendamento, o modelo retorna a probabilidade de falta, que o sistema apresenta em faixas de risco, e o médico é alertado sobre pacientes de alto risco.
- **Métricas de avaliação:** ROC AUC, *Average Precision* e *Brier Score*, além da relação entre as probabilidades previstas e as faltas de fato observadas.
- **Atualização do modelo:** como os dados e o comportamento dos pacientes mudam com o tempo, um *pipeline* de treinamento automático, executado periodicamente (de acordo com as anotações, a cada dois meses), usa uma janela móvel dos últimos dois anos. Ele treina um modelo candidato e o compara ao modelo ativo, usando dados de treino e de teste. A nova versão é gerada, validada e versionada, e um *e-mail* sugere à equipe se vale trocar o modelo ou mantê-lo. Assim, a ativação depende de decisão manual.
- **Cuidado conceitual:** o palestrante destacou que *correlação não implica causalidade*. O modelo identifica padrões preditivos, e não relações de causa e efeito.

Foi um ponto importante da fala: **a IA vai muito além das LLMs**. Esse recurso usa uma base de dados estruturados e Aprendizado de Máquina supervisionado, sem modelo de linguagem.

1.2 Chatbot com LLM e agentes: agendamento via WhatsApp

O atendimento 24 horas e o agendamento automático via WhatsApp combinam uma LLM com **agentes** que consultam *endpoints* da API durante a conversa, para descobrir horários disponíveis, profissionais e demais informações. Hoje o recurso é integrado com um parceiro, e a intenção é desenvolver uma solução própria. A ER Clinic também oferece API para integração com terceiros, com consultas nos *endpoints* (uso de RAG), *prompt engineering* e processos em n8n.

1.3 Reconhecimento de fala + LLM: transcrição da consulta

Um *widget* de terceiros, integrado ao prontuário, grava a consulta e envia fragmentos de áudio ao servidor. Ao final, o servidor reúne os fragmentos e faz o reconhecimento de fala (*speech-to-text*). O texto é contextualizado conforme a especialidade do profissional, descartando conversas irrelevantes e dados sem relação com a consulta, e uma LLM, guiada por *prompt engineering*, o organiza em um esquema predefinido com cinco campos: evolução, história da doença atual, hipótese diagnóstica, medicações e plano de tratamento. Por fim, o conteúdo entra no prontuário e pode ser revisado, complementado ou editado pelo profissional.

O ganho apontado foi permitir que o médico dê atenção plena ao paciente, em vez de olhar para a tela e digitar. O palestrante exibiu estudos recentes sobre *ambient AI scribes* que indicam redução da carga de documentação e/ou aumento do tempo de interação com o paciente.

1.4 LLM multimodal: análise de exames em foto ou PDF

A ER Clinic testou primeiro uma camada de OCR desenvolvida localmente (PyMuPDF e Tesseract), mas concluiu que um modelo pago multimodal funcionava melhor. Por isso, usa uma **LLM multimodal via OpenRouter**, hoje com o modelo Gemini Flash. O fluxo é:

1. o profissional envia a foto ou o PDF do exame;
2. o sistema registra os arquivos e cria uma tarefa assíncrona (Celery), com um tratamento diferente conforme o formato do arquivo;
3. a LLM recebe o conteúdo do exame, a idade e o sexo do paciente, além de instruções específicas (*prompt engineering*) sobre o formato de saída;
4. cada item é estruturado em um JSON com descrição, valor, unidade, intervalo de referência e classificação (normal, alto, baixo ou crítico);
5. a IA gera um parecer geral resumindo as alterações relevantes, sem substituir a avaliação profissional;
6. os resultados são gravados no exame e no prontuário, permitindo acompanhar a evolução dos indicadores em gráficos.

1.5 LLM de sumarização: resumo do prontuário

O resumo é pensado para o paciente de longa data: antes de ele sentar na cadeira, o médico já pode ter um resumo para relembrar os pontos importantes. Um algoritmo em Python/Django percorre os diversos módulos do prontuário (anamnese, evoluções, exames, prescrições, medicamentos, alergias, diagnósticos, documentos), filtra o que é pertinente, ordena do atendimento mais recente para o mais antigo e envia o histórico organizado à LLM junto com instruções da especialidade do profissional. A resposta é um JSON que o sistema transforma em resumo navegável, com links de referência para o trecho original, e dados estranhos são destacados em vermelho. Depois da geração inicial, as atualizações são incrementais, com o resumo anterior mais o novo atendimento, sem reprocessar todo o histórico. Modelos de sumarização do Hugging Face foram testados, mas os modelos comerciais, acessados via OpenRouter, tiveram resultados melhores.

1.6 RAG: Copiloto Clínico Córtex

O Córtex é uma arquitetura de copilotos clínicos configuráveis, cada um com seu *prompt*, sua LLM e sua base privada de conhecimento (protocolos, diretrizes e documentos do próprio médico ou da clínica). Em vez de retreinar a LLM, os documentos são fornecidos como contexto a cada consulta por meio de **RAG**:

1. **extração** do conteúdo dos documentos;
2. ***chunking***: divisão em trechos menores, com sobreposição para preservar o contexto;

3. ***embeddings***: transformação dos trechos em vetores numéricos;
4. **base vetorial** para armazenar os vetores;
5. **recuperação** por busca semântica dos trechos relevantes;
6. ***reranking*** para selecionar os mais pertinentes;
7. **geração**: a LLM recebe a pergunta, o *prompt* e o contexto recuperado e produz a resposta.

Nas anotações, um ponto econômico: o cliente investe na criação do protocolo e, depois, nas consultas, não enche o contexto da LLM, o que mantém o custo de processamento baixo por consulta. O copiloto verifica se há um protocolo para a situação relatada pelo paciente e, se houver, sugere as ações correspondentes, sempre com referências.

1.7 Visão computacional (planejada): Cervix

Na seção "o que vem por aí", o palestrante apresentou o **Cervix**, um assistente de laudos para colposcopia: a IA identifica regiões de interesse na imagem, o profissional avalia e então emite o laudo, que vai para o prontuário.

2. Avaliação da relação cenário/técnica: concordâncias e mudanças que poderíamos indicar

2.1 Pontos em que concordamos

- **A divisão de papéis entre IA e profissional.** Todos os recursos mantêm o ser humano no circuito: a transcrição é editável, o parecer de exames não substitui a avaliação médica e o copiloto apenas sugere. Isso é coerente com o conceito de *sistema de apoio à decisão*, no qual a decisão final e a responsabilidade ficam com o profissional.
- **Escolher a técnica pelo problema.** Para prever faltas, dados estruturados e Machine Learning supervisionado resolvem bem, sem precisar de LLM. Concordamos que nem tudo precisa de IA generativa e que, às vezes, o básico é mais eficiente.
- **Atualização controlada do modelo.** Comparar um modelo candidato ao ativo, versionar e exigir validação manual antes de ativar evita trocar por um modelo que não melhorou de fato.
- **RAG em vez de retreinar a LLM.** Mantém o conhecimento privado, atualizável e rastreável, e custa menos do que retreinar a cada mudança de protocolo.
- **Camadas de cuidado (*guardrails*).** Instruções para não inventar dados, formato JSON obrigatório, contexto de idade e sexo, validação dos links de origem, *escape*

de HTML e registro de erros e de modelos usados reduzem alucinações e dão rastreabilidade.

- **Decisões baseadas em teste.** A troca do OCR local por modelo multimodal e dos modelos do Hugging Face por modelos comerciais foi feita depois de comparar resultados, e não por *hype*.
- **Atenção à regulação e à privacidade.** Foram citadas a Resolução CFM n.º 2.454/2026 (níveis de risco: quanto maior o impacto da decisão, maior a supervisão humana) e a LGPD (dados de saúde são dados pessoais sensíveis), além do cuidado de não enviar mais dados do que o necessário à IA.

2.2 Pontos de atenção e mudanças que poderíamos indicar

Cenário	Ponto de atenção	Sugestão de mudança
Risco de falta (XGBoost)	Variáveis como o convênio podem refletir condição socioeconômica e gerar viés. O alerta pode levar a práticas questionáveis, como *overbooking* ou menor prioridade para certos pacientes.	Avaliar o desempenho por subgrupos; usar interpretabilidade (importância das variáveis, SHAP); validar por **divisão temporal** (treinar no passado e testar no futuro); escolher o limiar de alerta conforme o custo de falsos positivos e negativos; comparar com modelos simples (regressão logística, árvore de decisão) para justificar a complexidade; usar o alerta só para ações de apoio (lembrete, confirmação), nunca para negar atendimento.
Agendamento por chatbot	Hoje depende de um parceiro, e o agente atua sobre dados de pacientes pelo WhatsApp.	Seguir com o desenvolvimento próprio, exigindo confirmação explícita antes de efetivar o agendamento, com transferência para atendente humano quando o bot não resolver e registro das interações.

Cenário	Ponto de atenção	Sugestão de mudança
Transcrição da consulta	Há duas arquiteturas em avaliação: enviar o áudio em fragmentos ao servidor (mais controle, mas é preciso tratar formatos, conectividade e ordem dos fragmentos) ou transcrever no *frontend* e enviar só o texto (menos dados trafegados, mas qualidade e compatibilidade variam). O áudio e a transcrição são guardados.	Fazer o protótipo comparativo já previsto, medindo erro de transcrição em português e em termos médicos, latência e custo. Considerar uma solução híbrida (no dispositivo quando houver suporte e no servidor como alternativa) e um modelo aberto de reconhecimento de fala hospedado por eles, o que ajudaria nos custos. Definir prazo de descarte do áudio e consentimento do paciente, e identificar no prontuário o que foi gerado por IA e revisado.
Exames (LLM multimodal)	A LLM pode trocar valor ou unidade. Temperatura zero reduz a aleatoriedade, mas não garante que a resposta esteja correta.	Adicionar validações determinísticas (faixas plausíveis, unidades), exibir o original ao lado do extraído, sinalizar baixa confiança e fazer auditoria por amostragem, medindo a taxa de acerto da extração.
Resumo do prontuário	Risco de omitir algo relevante (como alergias) ou dar ênfase indevida a um dado.	Incluir por regra, e não só pela LLM, itens críticos como alergias e medicações contínuas; avaliar os resumos periodicamente com médicos usando uma lista de verificação.
Córtex (RAG)	A qualidade depende dos documentos e da recuperação. A própria equipe reconhece o desafio de verificar se a resposta corresponde às fontes.	Montar um conjunto de perguntas de teste com métricas de recuperação e de fidelidade à fonte; mostrar os trechos e páginas citados; controlar versão e vigência dos protocolos; responder que não há evidência quando faltar base, em vez de completar com conhecimento externo.
Dependência de provedores externos	OpenRouter, OpenAI, Pinecone e Cohere representam custo, risco de indisponibilidade e exposição de dados de saúde.	Manter uma camada de abstração para trocar modelos com facilidade, avaliar modelos abertos (coerente com o objetivo declarado de ter uma LLM própria por causa dos custos) e exigir contratualmente a não retenção e o não uso dos dados para treino de terceiros.

Cenário	Ponto de atenção	Sugestão de mudança
Cervix (imagem)	Imagens médicas têm alto impacto clínico.	Validar com base anotada por especialistas e relatar sensibilidade e especificidade; manter a IA apenas como marcadora de regiões de interesse, com o laudo sempre emitido pelo profissional; verificar o enquadramento regulatório como software médico.

3. Quais serviços o Robertson tem

3.1 ER Clinic

A ER Clinic é um sistema Web por assinatura mensal (SaaS) para a gestão de clínicas e consultórios, com 11 anos de atuação. Seus módulos incluem prontuário eletrônico, agenda eletrônica, parte financeira e gestão, com painel de indicadores de atendimento. Os recursos de IA que fazem parte dessa jornada do paciente são:

- **Agendamento:** chatbot para WhatsApp com atendimento 24 h e agendamento automático, e alerta para pacientes com alto risco de não comparecer.
- **Transcrição da consulta:** escuta a consulta e preenche automaticamente evolução, história da doença atual, hipótese diagnóstica, medicações e plano de tratamento, além de gerar resumo automático do prontuário.
- **Exames:** a partir da foto ou PDF, destaca resultados fora dos padrões de referência, organiza as informações, gera um parecer final de apoio à análise clínica e armazena o histórico para acompanhar a evolução em gráficos.
- **Resumo do prontuário:** resumo com links de referência para os trechos originais.
- **Copiloto Clínico Córtex:** copilotos configuráveis que consultam a base privada de conhecimento do médico (protocolos, artigos, documentos) e sugerem condutas, exames e tratamentos com referências.
- **API para integração com terceiros:** permite que outros *softwares* se comuniquem com a plataforma, com gestão de permissões.
- **Em desenvolvimento:** Cervix, assistente de laudos para colposcopia.

3.2 Outra iniciativa apresentada: Treino Scout

O palestrante também apresentou o **Treino Scout**, projeto voltado ao esporte que “transforma dados em resultados para elevar o desempenho de atletas”, com torneios de inte-

gração, *scout* de atletas e IA para inferência na identificação de categorias e sugestão de treino com base no desempenho registrado nos *scouts*.

4. Tecnologias e ferramentas utilizadas

Camada	**Tecnologia / uso informado na palestra**
Modelo de ML tradicional	XGBoost (*gradient boosting*) para o risco de falta; métricas ROC AUC, *Average Precision* e *Brier Score*
LLMs	Gemini Flash em uso, GPT-5 citado como exemplo de configuração; acesso a vários modelos pelo OpenRouter, que centraliza o pagamento e permite escolher o modelo
Prompt engineering	Definição do formato de resposta (JSON), regras de classificação, instruções de não inventar dados e de preservar valores originais
RAG	*Embeddings* OpenAI (`text-embedding-3-small`), base vetorial Pinecone, *reranking* com Cohere Rerank
Processamento de documentos	PyMuPDF e Tesseract OCR (primeira abordagem), depois LLM multimodal; arquivos de imagem enviados em Base64
Backend	Python, Django (API REST), Celery e Redis para processamento assíncrono
Integrações e automação	API própria para terceiros, *endpoints*, n8n e agentes para o agendamento
Reconhecimento de fala	*Widget* de parceiro hoje; solução própria em estudo (ASR/STT via API ou modelo hospedado)
Testado e descartado	Camada de OCR local e modelos de sumarização do Hugging Face

5. Relação com os nossos estudos de IA: PyCaret, scikit-learn, predição e previsão

5.1 Predição e previsão

Nos nossos estudos, **predição** é identificar ou classificar um resultado a partir dos dados disponíveis, e **previsão** é estimar acontecimentos futuros considerando a dimensão temporal (séries temporais). O alerta de falta da ER Clinic é um caso de **predição**: um classificador binário que, a partir das características de um agendamento, estima a probabilidade da classe “faltará”. Embora o evento seja futuro, o modelo não trabalha com uma série temporal. Já a previsão apareceria em usos como estimar a demanda de consultas ou a ocupação da agenda nas próximas semanas, que seria uma extensão natural para a gestão da clínica.

5.2 scikit-learn

O pipeline de falta é parecido com o que fizemos com a base de glicose. Ele usa dados estruturados, separação entre treino e teste, treinamento (`fit`), inferência (`predict`

e `predict_proba`) e avaliação por métricas. O XGBoost é uma implementação de *gradient boosting* de árvores de decisão, a mesma família do `DecisionTreeClassifier` e do `GradientBoostingClassifier` que comparamos, e possui interface compatível com o scikit-learn (`XGBClassifier`). As métricas usadas por eles também existem no scikit-learn:

Palestra	**scikit-learn**	**Relação com o que estudamos**
ROC AUC	`roc_auc_score`	Complementa acurácia e F1, avaliando o modelo em vários limiares
Average Precision	`average_precision_score`	Útil quando há desbalanceamento (poucas faltas), no lugar da acurácia
Brier Score	`brier_score_loss`	Mede a qualidade das probabilidades, algo que não vimos nas métricas de classe
Comparar candidato e modelo ativo	Mesmo `train_test_split` e mesmas métricas	Equivale a comparar vários modelos em um ranking, como fizemos pelo F1-*macro*
Janela móvel de dois anos	Divisão temporal em vez de aleatória	Diferente do `train_test_split` com `random_state`, que usamos

Um experimento análogo, com colunas ilustrativas, seria:

```
from xgboost import XGBClassifier
from sklearn.metrics import (roc_auc_score,
    average_precision_score, brier_score_loss)

modelo = XGBClassifier(eval_metric='logloss')
modelo.fit(X_train, y_train)
proba = modelo.predict_proba(X_test)[:, 1]

print(roc_auc_score(y_test, proba))
print(average_precision_score(y_test, proba))
print(brier_score_loss(y_test, proba))
```

5.3 PyCaret

O PyCaret é uma biblioteca de Machine Learning de baixo código que automatiza o fluxo de preparação, comparação, ajuste e finalização de modelos. A rotina de reavaliar periodicamente um modelo candidato contra o atual lembra o que o PyCaret faz com `compare_models()`, que treina e ranqueia vários algoritmos (incluindo `xgboost`) com as mesmas métricas. Um experimento de comparação rápida para a base de faltas seria:

```
from pycaret.classification import *

setup(data=df, target='faltou', session_id=42)
melhor = compare_models(sort='AUC')
final = finalize_model(tune_model(melhor))
```

O PyCaret é útil para explorar rapidamente quais modelos funcionam melhor. Em produção, como na ER Clinic, é preciso complementar com o controle de versões, a validação manual e o monitoramento que o palestrante descreveu.

5.4 Outros conceitos da disciplina na palestra

Conceito estudado	**Onde aparece na ER Clinic**
Dados estruturados	Base histórica de agendamentos, usada no alerta de falta
Reconhecimento de padrões	Padrões de comportamento (histórico de faltas, dia e horário) que o XGBoost identifica
Sistema de apoio à decisão	Parecer de exames, resumo do prontuário e Copiloto Córtex: a IA informa e o profissional decide
Sistema de recomendação	Parcialmente no Córtex, que sugere condutas e exames com base em protocolos, sempre sob decisão do médico
Diagnóstico	Apoio à análise de exames e, futuramente, ao laudo de colposcopia (Cervix)
Processamento de linguagem natural	Transcrição, resumo, *chatbot* e RAG, que usam LLMs
Monitoramento/ sensoriamento	Citado como área de aplicação da IA (*wearables*), mas fora do escopo dos produtos apresentados